



Universidade de Brasília

Universidade de Brasília
Instituto de Ciências Exatas – Departamento de Ciência da Computação
Engenharia de Computação

Orientador: Prof. Jan Mendonça Corrêa

Predição de Interrupções no Fornecimento de Energia Elétrica no Distrito Federal

**Um estudo comparativo entre XGBoost e redes
neurais recorrentes bidirecionais**

Giovanni Minari Zanetti Mateus Gomes de Araújo

Brasília, 2026


Dados públicos de clima e operação
conseguem prever quantas interrupções
ocorrerão nos próximos dias?

- ▶ **Alvo:** número diário de interrupções no Distrito Federal.
- ▶ **Comparação:** XGBoost, Bi-LSTM e Bi-GRU.
- ▶ **Horizontes:** 1, 3, 7 e 14 dias à frente.

Fonte: Monografia, Capítulo 1.

As interrupções cresceram 65,3% em oito anos

Contexto operacional



183,5
interrupções/dia
em 2017
303,4

interrupções/dia
em 2025
1.424

pior dia observado

Fonte: ANEEL; elaboração dos autores, 2017–2025.

Cenário atual

- ▶ Redes aéreas de 13,8 kV expostas ao clima do Cerrado.
- ▶ Chuvas intensas, rajadas e calor pressionam a infraestrutura.
- ▶ Resposta predominantemente reativa após a interrupção.

Oportunidade

- ▶ Pré-posicionar equipes e materiais.
- ▶ Planejar comunicação e contingência.
- ▶ Apoiar uma manutenção orientada por risco.

A previsão não elimina a incerteza, mas transforma histórico e clima em antecedência operacional.

1. **Base integrada inédita**

3.073 dias de clima, interrupções e consumo, provenientes de INMET, ANEEL e SAMP.

2. **Memória temporal explícita**

40 atributos derivados com defasagens, médias móveis, variabilidade e sazonalidade.

3. **Comparação equânime**

Três arquiteturas avaliadas com separação temporal estrita e os mesmos 365 dias de teste.

4. **Escolha por horizonte**

Desempenho comparado em previsões diretas de 1, 3, 7 e 14 dias.

Fonte: Monografia, Seção 1.4.

Três fontes públicas sustentam o estudo

Dados e escopo



INMET temperatura, precipitação, velocidade, rajada e direção do vento.

ANEEL registros de interrupções e fatores geradores.

SAMP consumo mensal de energia no Distrito Federal.

2017–2025

período analisado

3.073

dias brutos **3.066**

observações finais


Delimitação

Distribuição de energia no DF, resolução diária e dados meteorológicos da estação A001 de Brasília.

Fonte: INMET, ANEEL e SAMP; Monografia, Seções 1.3 e 3.2.

O pipeline integra dados e gera previsões

Processamento



- ▶ Somatório para chuva e interrupções; médias para temperatura e vento.
- ▶ Interpolação linear apenas em lacunas curtas.
- ▶ Extremos climáticos reais foram preservados.

Fonte: Monografia, Seções 3.5 e 3.6.

Memória recente

- ▶ Defasagens de 1 a 7 dias.
- ▶ EMAs de 3, 7 e 14 dias.
- ▶ Desvio padrão móvel de 7 dias.
- ▶ Janela sequencial de 14 dias nas RNNs.

Contexto do sistema

- ▶ Temperatura, chuva e cinco variáveis de vento.
- ▶ Consumo mensal de energia.
- ▶ Dia da semana e posição no ano.
- ▶ Codificação seno/cosseno do mês.

As mesmas informações históricas disponíveis em t alimentam a previsão direta de $t + h$.

O teste preserva a ordem do tempo

Protocolo sem vazamento de dados



- ▶ Normalização ajustada apenas no treinamento.
- ▶ Modelos independentes para cada horizonte.
- ▶ Nenhuma previsão intermediária é reutilizada.

Fonte: Monografia, Seções 3.7, 3.8 e 3.10.

XGBoost Árvores sequenciais sobre atributos tabulares.
300 árvores, profundidade 4 e busca em grade com validação temporal.

Bi-LSTM Memória recorrente com estado de célula.
2 camadas, 64 unidades, janela de 14 dias e dropout 0,4.

Bi-GRU Memória recorrente mais compacta.
2 camadas, 64 unidades, janela de 14 dias e dropout 0,4.


Comparação

MAE, RMSE, R^2 e MAPE sobre os mesmos 365 dias de teste.

Fonte: Monografia, Seção 3.9.

A série revela tendência e sazonalidade

2017–2025





- ▶ Picos recorrentes entre outubro e março.
- ▶ Vale operacional predominante entre maio e agosto.
- ▶ Eventos acima de 1.000 interrupções permanecem raros.

Fonte: ANEEL; elaboração dos autores, Figura 4.1.

A série mantém memória além de 14 dias

Autocorrelação




Leitura

A dependência temporal significativa fundamenta lags, EMAs e a janela recorrente de 14 dias.

Fonte: Elaboração dos autores, Figura 4.5.

A agregação revela melhor o sinal climático

Correlação com interrupções



0,59

direção do vento,
mensal **0,54**

precipitação, mensal
0,48

consumo, mensal

Fonte: INMET e ANEEL; elaboração dos autores, Figura 4.8.

XGBoost e Bi-LSTM empatam em um dia

Resultados para $h = 1$



Modelo	MAE	RMSE	R^2	MAPE
XGBoost	61,09	99,72	0,409	20,64%
Bi-LSTM	62,71	98,80	0,420	20,94%
Bi-GRU	73,44	119,21	0,156	26,18%

2,7%

diferença de MAE entre
XGBoost e Bi-LSTM


Interpretação

A engenharia manual
de atributos equiparou
a memória aprendida
pela Bi-LSTM no
curtíssimo prazo.

Fonte: Elaboração dos autores; 365 dias de teste.

Os modelos suavizam os maiores picos

XGBoost no conjunto de teste




O desempenho médio é útil, mas os maiores eventos ainda são sistematicamente subestimados.

Fonte: Elaboração dos autores, Figura 4.16.

O erro cresce nos dias mais críticos

Heteroscedasticidade e severidade



MAE do XGBoost

Normal (< 200) **30,1**

20,3% dos dias

Moderada (200–400) **38,9**

66,0% dos dias

Severa (> 400) **135,9**


13,7% dos dias

Previsões pontuais devem evoluir para intervalos de incerteza.

Fonte: Elaboração dos autores, Tabela 4.4 e Figura 4.23.

O histórico domina o curto prazo

Importância no XGBoost



Principais sinais


- ▶ Interrupções em t .
- ▶ Lag de 1 dia.
- ▶ Sazonalidade mensal.
- ▶ EMA de precipitação.

Importância preditiva não implica causalidade.

Fonte: Elaboração dos autores, Figura 4.26.

A hierarquia muda com o horizonte

MAE em previsão direta



$h = 1$ **XGBoost**

MAE 61,1

$h = 3$ **Bi-LSTM**

MAE 72,1

$h = 7$ **Bi-GRU**

MAE 71,8

$h = 14$ **Bi-GRU**

MAE 62,8

Fonte: Elaboração dos autores; 365 alvos idênticos por horizonte.

Não existe um único modelo vencedor

Escolha guiada pela operação



Horizonte	Modelo indicado	Uso operacional
1 dia	XGBoost ou Bi-LSTM	Alerta de curtíssimo prazo, com boa relação entre erro e custo.
3 dias	Bi-LSTM	Planejamento de equipes e materiais para a próxima janela operacional.
7 e 14 dias	Bi-GRU	Preparação logística e acompanhamento preventivo de médio prazo.

Estratégia recomendada

Combinar modelos por horizonte e retrainar periodicamente para acompanhar mudanças na série.

Fonte: Monografia, Seções 5.2 e 5.3.

O escopo dos resultados ainda é restrito

Limitações



Dados

- ▶ Uma única estação meteorológica.
- ▶ Resolução diária e geografia agregada.
- ▶ Ausência de topologia, idade dos ativos e vegetação.

Modelagem

- ▶ Apenas 2.687 sequências para as RNNs.
- ▶ Direção do vento tratada por média simples.
- ▶ Previsões pontuais sem intervalo de incerteza.

Próximos passos

Dados horários e espaciais, múltiplas estações, NDVI/LiDAR, índices ENSO e previsão probabilística.

Fonte: Monografia, Seção 5.5 e Capítulo 6.

A implantação pode começar como alerta

Caminho para manutenção preditiva



1. **Atualizar diariamente** as bases climáticas e operacionais.
2. **Gerar risco por horizonte** com o modelo mais adequado.
3. **Acionar limiares** para equipes, materiais e comunicação.
4. **Monitorar erro e deriva** e retrainar com dados recentes.

O modelo atua como sistema de alerta: informa risco e incerteza, enquanto a decisão permanece com a operação.

Fonte: Monografia, Seções 5.6 e 6.4.

1. O clima e o histórico recente contêm **sinal preditivo relevante**.
2. Em $h = 1$, **XGBoost e Bi-LSTM** apresentam desempenhos próximos.
3. Em horizontes maiores, as **redes recorrentes assumem vantagem**.
4. Eventos extremos continuam sendo o principal desafio de previsão.

Resposta à pergunta de pesquisa

Sim, é possível antecipar interrupções com dados públicos, desde que o modelo seja escolhido pelo horizonte e a incerteza seja considerada.



Obrigado!

Perguntas e discussão

Giovanni Minari Zanetti · Mateus Gomes de Araújo

Métricas completas confirmam a inversão

Reserva: métricas multi-horizonte



Modelo	$h = 1$		$h = 3$		$h = 7$		$h = 14$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
XGBoost	61,09	99,72	76,71	117,96	81,57	129,82	69,50	113,24
Bi-LSTM	62,71	98,80	72,08	117,42	77,70	126,25	66,12	108,40
Bi-GRU	73,44	119,21	75,78	119,72	71,81	117,88	62,79	104,50

O XGBoost atinge $R^2 = -0,001$ em $h = 7$; a Bi-GRU atinge $R^2 = 0,351$ em $h = 14$.

Fonte: Arquivo de métricas multi-horizonte do repositório.

XGBoost tem menor custo operacional

Reserva: custo computacional



Critério	XGBoost	Bi-LSTM	Bi-GRU
Parâmetros/nós	~5.000 nós	~63.600	~49.900
Treino em CPU	< 2 min	~25 min	~20 min
GPU	Não	Sim	Sim
Inferência	< 1 ms/dia	~5 ms/dia	~4 ms/dia
Memória	~50 MB	~200 MB	~180 MB

Leitura


Em $h = 1$, o ganho operacional do XGBoost é sua simplicidade; em horizontes longos, a vantagem preditiva das RNNs pode justificar o custo adicional.

Fonte: Estimativas dos experimentos; Monografia, Seção 5.7.

As redes concentram erros perto de zero

Reserva: distribuição residual

Distribuição do Erro Residual (KDE) nos Modelos Preditivos



- ▶ Bi-LSTM e Bi-GRU: maior concentração em torno de zero.
- ▶ XGBoost: distribuição mais achatada e comportamento mais conservador.

Fonte: Elaboração dos autores, Figura 4.22.

Repositório

<https://github.com/Mathweuzz/>

Modelagem-Preditiva-de-Falhas-na-Rede-Eletrica-do-Distrito-Federal

Fontes de dados

- ▶ INMET – Dados Históricos, estação A001/Brasília.
- ▶ ANEEL – Interrupções de Energia Elétrica nas Redes de Distribuição.
- ▶ ANEEL/SAMP – Balanço de energia por mercado.

Referências metodológicas centrais

- ▶ Chen e Guestrin (2016) – XGBoost.
- ▶ Hochreiter e Schmidhuber (1997) – LSTM.
- ▶ Cho et al. (2014) – GRU.